

特集 「宇宙に挑む人工知能技術」

ハイパースペクトル画像処理が拓く新しい地球観測

Hyperspectral Image Processing for Advanced Earth Observation

横矢 直人
Naoto Yokoya

東京大学大学院工学系研究科先端学際工学専攻
Dep. of Advanced Interdisciplinary Studies, Graduate School of Engineering, the University of Tokyo.
yokoya@sal.rcast.u-tokyo.ac.jp

岩崎 晃
Akira Iwasaki

(同上)
aiwasaki@sal.rcast.u-tokyo.ac.jp

Keywords: hyperspectral data processing, earth observation.

1. はじめに

ハイパースペクトルイメージング (hyperspectral imaging) は対象物からセンサに入射する電磁スペクトルを平面的に観測する技術であり、イメージングスペクトロメータ (imaging spectrometer) とも呼ばれる。ハイパースペクトル画像は、図1のように空間方向に加え波長方向に次元をもつキューブ状のデータとなる。各ピクセルで連続的な電磁スペクトル特性が得られるため (図1右下)、観測物の詳細な情報把握が可能となり、森林管理、精密農業、生態系監視、資源探査、海底深度計測など、地球観測における幅広い用途に役立つ [Clark 05, Haboudane 04, Kruse 03, Underwood 03, Ustin 04]。地球観測以外でも、食品や医薬品の品質管理などさまざまな分野で利用されている [Gowen 07, Lyon 02]。

ハイパースペクトルカメラの歴史は、1980年代にアメリカ航空宇宙局 (NASA: National Aeronautics and Space Administration) のジェット推進研究所 (JPL: Jet Propulsion Laboratory) で、新しい地球観測センサとして開発された AIS (Airborne Imaging Spectrometer) や AVIRIS (Airborne Visible InfraRed Imaging Spectrometer) に端を発する。“hyperspectral” は「超多次元のスペクトルデータ」を意味するものとして、1985年に Goetz, et al. が Science 誌で発表した論文 [Goetz 85] で初めて用いられた。AVIRIS は1987年に初めて航空撮影を行って以降、現在も運用が続けられており、 $0.4\sim 2.5\ \mu\text{m}$ を224バンドで撮影する高波長分解能を生かし、生態学、海洋学、地質学、雪水文学、大気の研究などさまざまな研究分野で利用されている。 $2.0\sim 2.4\ \mu\text{m}$ の範囲に鉱物の特徴的なスペクトル吸収特性が現れるため、従来型のマルチスペクトル (図1右上)

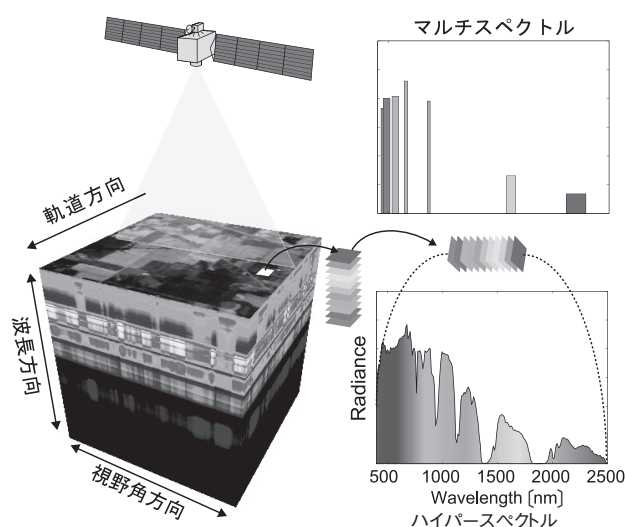


図1 ハイパースペクトル画像

カメラでは難しかった鉱物の詳細な識別が可能となる。また、植物の反射スペクトルに関しても、 $0.4\sim 2.5\ \mu\text{m}$ には、植物色素濃度、葉の細胞構造、葉の水分含量の情報が含まれている。このため、ハイパースペクトル画像を解析することで、植物種のマッピング、健康状態の把握、バイオマスの評価などが可能となる。AVIRISのほかにも、ITRES Research Limited が販売する CASI (Compact Airborne Spectrographic Imager)、Specim が販売する AISA、Integrated Spectronics が製造する HyMap などが商業利用されている。各センサの観測波長域やバンド数を表1に示す。

リモートセンシングにおけるハイパースペクトルカメラの撮像方式は、図2に示す二つの走査型が主流である。Wiskbroom方式では、機械式走査 (鏡の回転) を利用して軌道直行方向に各点のスペクトルを連続的に取得する。駆動機構が必要で1点の観測時間は短い、広範囲

表1 地球観測用ハイパースペクトルカメラ

Sensor	Agency/ Company	Number of Bands	Spectral Range [μm]	Start [year]
航空機搭載型				
AIS	NASA	128	1.2~2.4	1982
AVIRIS	NASA	224	0.4~2.5	1987
CASI	ITRES Research Limited	228	0.4~1.0	1989
AISA	Spectral Imaging	288	0.43~1.0	1995
HyMap	Integrated Spectronics	126	0.45~2.5	1999
衛星搭載型				
Hyperion /EO-1	NASA	220	0.4~2.5	2000
CHRIS /PROBA	ESA	62	0.4~1.0	2001
PRISMA	ASI	238	0.4~2.5	2015
HISUI	METI	185	0.4~2.5	2016
EnMAP	DLR	244	0.4~2.5	2017
HypIRI	NASA	217	0.38~2.5 & 7.5~12	2022




図2 ハイパースペクトル画像の撮像方式

の観測に適している。Pushbroom方式では、軌道直方向のラインごとに分光画像を取得する。広い画角の集光光学系に対応した検出器が必要となるが、駆動機構が不要で各点の観測時間が比較的長い。

2000年代には技術実証的な衛星搭載型ハイパースペクトルセンサが登場した。NASAが2000年に打ち上げたEO-1 (Earth Observing-1) 衛星 [Ungar 03] に搭載されたHyperionは、 $0.4 \sim 2.5 \mu\text{m}$ を220バンドで観測する衛星搭載型ハイパースペクトルカメラである。Hyperionは10年以上稼働しており、森林、土地被覆、農業、侵入生物種、植生、火山活動、水資源など幅広い分野でその有効性が示された [Middleton 13]。欧州宇宙機関 (ESA: European Space Agency) が2001年に打ち上げたPROBA-1衛星に搭載されたCHRIS (Compact High-Resolution Imaging Spectrometer) [Barnsley 04] は $0.4 \sim 1.0 \mu\text{m}$ を62バンドで観測する小型の衛星搭載型ハイパースペクトルセンサであり、2通りのバンド数と地上サンプリング幅を選択できる点が特徴的である。

ハイパースペクトルカメラは、火星探査にも利用されている。2004年に火星周回軌道に入ったESAのMars Express Orbiterに搭載されたOMEGA (Observatoire pour la Minéralogie, l'Eau, les Glaces

et l'Activité) [Biring 06] や、2006年に火星周回軌道に到達したNASAのMars Reconnaissance Orbiterに搭載されたCRISM (Compact Reconnaissance Imaging Spectrometer for Mars) [Mustard 08] は、鉱物解析により、火星における水の存在とその変遷について多くの知見をもたらした。

現在、世界各国で次世代地球観測衛星センサとしてハイパースペクトルカメラが開発されている。日本では経済産業省 (METI: Ministry of Economy, Trade and Industry) を中心に、2016年の打上げを目指してHISUI (Hyperspectral Imager Suite) [Ohgi 10] を開発している。HISUIは、主に鉱物資源探査や農林水産分野での利用が期待される。ドイツでは、ドイツ航空宇宙センター (DLR: Deutsches Zentrum für Luft- und Raumfahrt) がEnMAP (Environmental Mapping and Analysis Program) [Sang 08] というミッションを進めている。2017年の打上げを予定しており、生態系の動的プロセスを計測・モデル化し、グローバルな地球環境をモニタリングすることを主な目的としている。イタリア宇宙機関 (ASI: Agenzia Spaziale Italiana) が開発中のPRISMA (PRecursore IperSpettrale della Missione Applicativa) [Galeazzi 08] は、ハイパースペクトルカメラと中解像度パナクロマティック (白黒) カメラで構成され、環境モニタリング、資源探査、作物分類、汚染監視などへの利用を想定している。NASAが開発予定のHypIRI (Hyperspectral Infrared Imager) [Chien 09] は、世界の生態系を研究し、火山活動、森林火災、干ばつなどの自然災害に関する重要な情報を提供することを目標としている。

ハイパースペクトル画像は波長方向の情報量が増えることで、スペクトル解析が可能となり利用用途が広がるという長所がある一方、多くのバンドが互いに相関することで生じるデータの冗長性や、解析目的に寄与しない波長情報は、解析結果を悪化させる可能性もある。そこで、高次元なスペクトルデータから有用な情報を取り出す技術が非常に重要であり、近年、ハイパースペクトル画像からの情報抽出に関する研究が盛んである [Bioucas-Dias 13, Plaza 09]。本稿では、クラス分類、ミクセル分解、ターゲット検出、高解像度化の四つの話題について、地球観測における最新のハイパースペクトル画像処理技術を紹介する。

2. クラス分類

ハイパースペクトル画像のクラス分類とは、各ピクセルに一つのクラスラベルを割り当てることである。植物種、鉱物、土地被覆などの分類図 [Clark 05, Kruse 03] を作成することは、森林管理、資源探査、生態系監視、地図作成などに役立つ。問題設定としては、クラスラベル付きサンプルを訓練データとして用いる教師あり分類

が主流である。高次元なハイパースペクトル画像に古典的な分類手法を適用するだけでは、必ずしも精度の良い分類結果は得られない。そこで、近年、機械学習を用いたハイパースペクトル画像のクラス分類が研究されてきた。

2.1 次元削減

クラス分類の前処理として、バンド選択や特徴抽出といった次元削減が重要である [Landgrebe 03]。バンド選択は、分類に役立つ波長帯のみを取り出して使う手法で、スペクトルの物理的意味を保持できるという利点がある。教師ありバンド選択では、訓練データにおいてクラスが分離しやすいバンドを選択する方法が一般的である [Bioucas-Dias 12]。

特徴抽出手法としては、主成分分析 (PCA : Principal Component Analysis) や最小ノイズ分率 (MNF : Minimum Noise Fraction) 変換 [Green 88] がよく用いられる。スペクトルを変数とする多次元空間 (スペクトル空間) において、PCA はデータの分散を、MNF は信号雑音比 (SNR : Signal-to-Noise Ratio) を最大化するように、座標軸を取り直す射影変換手法である。スペクトル特徴が低次元空間に射影されるため、変換後の上位成分を特徴量として使うと、ノイズの影響を軽減してクラスを分離しやすくなる。スペクトルの微分解析や、スペクトル吸収特性を強調する連続体除去 (continuum removal) [Clark 84] は、鉱物や植生のスペクトル解析で古くから利用されている。訓練データを使った特徴抽出では、クラス内分散を小さくしクラス間分散を大きくする線形判別分析 (LDA : Linear Discriminant Analysis) が有効である [Kumar 01]。

2.2 教師あり分類手法

次元削減を施したデータに分類器を適用して、クラス分類図が得られる。教師あり分類の基本的な手法としては、最近傍法、最尤法 (MLE : Maximum Likelihood Estimation)、決定木、LDA などがある。Spectral Angle Mapper (SAM) [Yuas 92] は、スペクトル空間における教師スペクトルと分類対象スペクトルの角度を類似度として最近傍法により分類を行う手法で、植生や鉱物の解析でよく用いられる。

多クラスロジスティック回帰 (MLR : Multinomial Logistic Regression)、ニューラルネットワーク [Benediktsson 99]、サポートベクタマシン (SVM : Support Vector Machine) [Melgani 04]、ランダムフォレスト [Ham 05] といった分類器の有効性が示されてきた。Decision Fusion [Benediktsson 99] は、複数の分類器で得られた結果を各ピクセルへの投票により統合することで、より正確なクラス分類図を得ることができる。

各ピクセルのスペクトルを独立したサンプルとして扱うと、分類マップに「ごま塩」状のノイズが発生する。

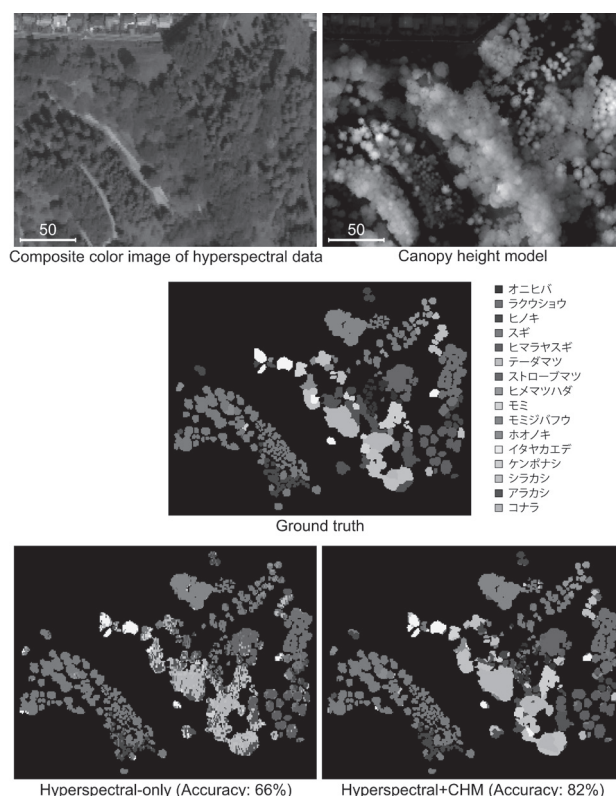


図3 ハイパースペクトル画像と LiDAR データを用いた樹種分類 [Matsuki 14]

スペクトル情報に加えて空間情報も考慮することで分類精度を上げるさまざまな試みが行われてきた。空間的特徴量を入力変数に加えることで、分類精度の向上が報告されている。モルフォロジー演算は空間的特徴量の抽出に有効である [Benediktsson 05]。各画素で算出した空間的特徴量は、複合カーネルによりスペクトル特徴量と効果的に組み合わせることができる [Camps-Valls 06]。空間情報を取り入れる別のアプローチとしては、画素ごとに分類した後に、後処理としてセグメンテーションや平滑化フィルタを用いる方法がある [Landgrebe 03]。これらは、分類器に手を加える必要がないため実用性が高い。

追加のデータとして、LiDAR (Light Detection and Ranging) から得られる高さ情報をハイパースペクトル画像と併せて使うことで、スペクトル情報だけでは分類が難しい似通ったクラスも高い精度で分類することができる [Dalponte 08, Matsuki 14]。図3に CASI で撮影したハイパースペクトル画像と LiDAR データから得られる樹冠の高さモデル (CHM : Canopy Height Model) を用いた樹種分類の結果を示す。従来のマルチスペクトル画像では分類が難しい 16 種類の樹種を、ハイパースペクトル画像を使うことで 66%、さらに CHM を活用することで 82% の精度で分類可能となる。これは、次元削減に PCA、分類器には SVM、訓練データには Ground truth の 10% を使用した場合の結果である。

2.3 半教師あり学習と能動学習

リモートセンシングにおける教師あり分類の課題は、訓練サンプル数が限られていることである。正確な訓練サンプルを得るためには、現地調査が有効であるが、広大な範囲を調査することは時間的にも金銭的にもコストが高い。また、人が行けない危険地帯や未開地域では、訓練データを作成することは困難であり、そもそもこれらの課題こそが、リモートセンシングを活用する動機でもある。したがって、限られた訓練サンプルからいかに正確で頑健な分類器を構築するかが重要である。この課題を克服するために半教師あり学習に基づく分類手法が研究されてきた [Bruzzone 06]。半教師あり学習は、限られた数のラベルありサンプルだけでなく、ラベルなしサンプルも利用することによって、分類器の精度を改善させるものである。

分類結果に対して専門家のフィードバックが得られる場合、訓練サンプル獲得のコストを抑えるためには、少ない回数のフィードバックで高い学習効果を目指す必要がある。このような理由から、能動学習 (active learning) が半教師あり手法と併せて研究されてきた [Tuia 11]。能動学習は、分類結果の信頼性が低いサンプルを機械が提示し、人間がラベル付けして訓練サンプル数を効率的に増やすものである。これらの機械学習をハイパースペクトル画像のクラス分類に適用することで、少ない訓練サンプル数でも高い精度のクラス分類図を作成できる。

3. ミクセル分解

一画素に対応する範囲に単一の構成要素しかない場合、この画素をピュアピクセルと呼ぶ。これに対して、一画素に複数の構成要素 (例えば、水や植物など) が混在するとき、この画素を **mixed pixel** の略称でミクセル (mixel) と呼ぶ (図4)。ハイパースペクトルカメラは SNR の制約から、空間分解能がマルチスペクトルセンサよりも低く、ミクセルが発生しやすい。スペクトル空間で分離可能な地表面の構成要素を端成分 (EM: endmember) と呼ぶ。ミクセルのスペクトルは、複数の端成分スペクトルが混合したものとなる。観測スペク




図4 ピュアピクセルとミクセル [Bioucas-Dias 12]

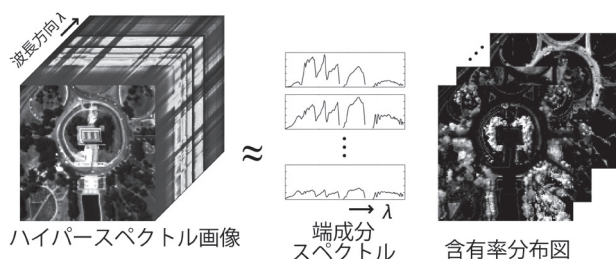


図5 ミクセル分解のイラスト

トルを、端成分スペクトルとその含有率に分解することをミクセル分解、あるいはアンミキシング (unmixing) と呼ぶ。分類が1画素に1クラスを割り当てるのに対して、ミクセル分解は1画素に複数クラスの存在割合を割り当てる問題となる。ハイパースペクトルデータ全体にミクセル分解を適用した場合、図5のように観測範囲に含まれる端成分スペクトルとその含有率分布図が得られる。ミクセル分解はブラインド信号源分離の一種であり [Zibulevsky 01]、マルチスペクトル画像を使った研究は古くから行われてきた [Adams 86]。ハイパースペクトル画像は豊富なスペクトル情報を活かすことで、高度なミクセル分解を実現できることから、近年盛んに研究されている [Bioucas-Dias 12, Keshava 02]。マルチスペクトルでは分離が難しい物質でも、高波長分解能で現れるスペクトル特性の差異からサブピクセルレベルでの存在割合を識別することが可能となる。

線形スペクトル混合モデルは、観測スペクトルが端成分スペクトルの線形和で表されることを仮定する。このモデルは、物理的解釈性が高く数学的にも簡素に表記できることから、ミクセル分解に広く用いられる。対象物からセンサに入射する光は一次反射光のみであることを仮定しており、現実世界とは異なるものの良い近似解を与えることが知られている。線形スペクトル混合モデルに基づくミクセル分解は、スペクトルライブラリ活用型とデータ駆動型の二つのアプローチが研究されてきた。

非線形なスペクトル混合によって、線形スペクトル混合モデルに基づくミクセル分解の結果に有意な誤差が生じることがある [Roberts 93]。非線形スペクトル混合には、鉱物などで起こるマイクロなレベルのものと、建物や木などのマクロな三次元構造に起因するものがある。前者については Hapke のモデルに基づく手法が提案されており、後者については二次反射光を考慮する双線形スペクトル混合モデルとその解法が提案されている [Bioucas-Dias 12]。非線形ミクセル分解はリモートセンシングによる検証や評価が非常に難しいことから、まだ発展途上の技術といえる。本稿では、線形スペクトル混合モデルに基づくミクセル分解手法について説明する。

3.1 スペクトルライブラリ活用型

スペクトルライブラリ活用型では、解析対象シーンに含まれる端成分スペクトルがスペクトルライブラリに含

まれることを前提とし、端成分の含有率を推定する問題となる。スペクトルライブラリには現地や実験室で計測したスペクトルを用いるのが一般的であるが、ピュアピクセルが存在し目視判読が可能な場合は、観測画像から手動で選択した端成分スペクトルを用いことも実用的である。前者の場合は、観測画像とスペクトルライブラリの整合性をとるために、ハイパースペクトル画像の大気補正が重要となる。

観測範囲に含まれる端成分スペクトルが既知の場合、各ピクセルにおける含有率推定は、観測スペクトルを目的変数、端成分スペクトルを説明変数とする回帰分析によって求められる。ただし、全観測スペクトルに対してすべての端成分スペクトルを説明変数として用いると、相関の高い端成分スペクトルに起因する多重共線性から、含有率の推定誤差が容易に増大するという問題がある。Roberts, et al. は、1画素に含まれる端成分数は各画素で異なり、それほど多くないという物理的事実に着目し、MESMA (Multiple Endmember Spectral Mixture Analysis) [Roberts 98] を提案した。MESMA はピクセルごとに端成分の数と種類を変化させ、再構成誤差を小さくする端成分の組合せを、端成分数 2 から順にスペクトルライブラリ中で探索する手法である。

端成分スペクトルが既知の状況における含有率推定は、含有率の非負値性と、各画素におけるすべての端成分の含有率を足すと 1 になる、という物理的条件を考慮すると、拘束条件付きの最小二乗法に帰着し [Heinz 01], 全域最適解が得られる。スペクトルライブラリ活用型では、スパース回帰を用いるアプローチが近年注目されている [Iordache 11]。これは、1画素に含まれる端成分数は少なく、端成分は画像全体で共有され、含有率分布は空間的に連続的である、といった物理的条件をスパース回帰問題に帰着させたものである。MESMA の考え方をより一般的な最適化問題に落とし込んだ手法といえる。

3.2 データ駆動型

データ駆動型のミクスル分解は、観測データの構造から自動的に端成分スペクトルと含有率分布図を推定するアプローチである。端成分スペクトルの推定と含有率の推定の二つの過程で構成される。全端成分についてピュアピクセルの存在が仮定できる（ピュアピクセル仮定と呼ぶ）とき、含有率の非負値性から、図 6 左のように端




図 6 線形スペクトル混合モデルの幾何学的特性

成分スペクトルは多次元空間においてデータサンプルが構成する単体の頂点に位置すると考えられる。したがって、端成分スペクトルの推定は、データによって張られる単体の頂点を推定する問題となる。

このような幾何学的アプローチで有名な手法には、PPI (Pixel Purity Index) [Boardman 93], N-FINDR [Winter 99], VCA (Vertex Component Analysis) [Nascimento 05] などがあげられる。PPI はランダムに射影ベクトルを生成し、一次元にデータサンプルを射影した際の端点に投票することを繰り返して単体の頂点を求める。N-FINDR は端成分によって構成される単体の体積を最大化することを目的として、最適な端成分スペクトルの組合せを求める。VCA はすでに求めた端成分で張られる部分空間に直交する方向にデータを射影し、射影先での端点を新たな端成分として繰り返し端成分を求める。ピュアピクセル仮定が成り立たない場合（図 6 右）、端成分スペクトルの推定はより難しい問題となる。SISAL (Simplex Identification via variable Splitting and Augmented Lagrangian) [Bioucas-Dias 09] は、観測データすべてを含む単体のうち、その体積を最小化する単体の頂点を端成分スペクトルとして推定する幾何学的アプローチである。

幾何学的アプローチでは、次元削減が大きな役割を果たす。PPI では MNF を、また、VCA では PCA を前処理で使用する。バンド選択や連続体除去といった古典的な前処理もデータ駆動型の端成分抽出に有効であ

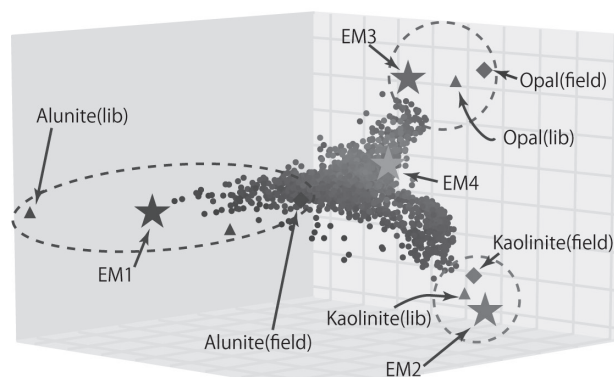



図 7 データ駆動型端成分推定と現地調査およびライブラリの比較 [Itoh 13]

る [Itoh 13]. 図 7 に SISAL によって推定した端成分スペクトルを、主成分空間で現地計測やスペクトルライブラリと比較したイラストを示す. 解析には鉱物のテストサイトとして有名なアメリカネバダ州 Cuprite 鉱山を, AVIRIS で撮影したデータを使用した. データは反射率で, 3 種類の鉱物 (Kaolinite, Alunite, Opal) が解析対象物である. 前処理にバンド選択と連続体除去を用いることで, SISAL は現地計測やスペクトルライブラリに近い単体の頂点を端成分として推定できた.

端成分スペクトルと含有率の同時推定にはブラインド信号源分離手法として有名な独立成分分析 (ICA: Independent Component Analysis) を適用できる [Bayliss 97]. ただし, 異なる端成分でも, スペクトルや含有率分布に相関がある場合が多く, 物理的拘束条件に合致した解法ではない. 観測データ, 端成分スペクトル, 含有率をそれぞれ行列で表したとき, ミクセル分解は行列分解の問題とみなせる. 物理的条件から行列のすべての成分は非負値なので, 非負値行列因子分解 (NMF: Nonnegative Matrix Factorization) [Lee 99] を適用することで, 端成分スペクトルと含有率を同時に推定できる [Miao 07]. データ駆動型アプローチでは, 最後にスペクトルライブラリを参照し, 最も近いスペクトルを探すことで推定した端成分スペクトルの物質を同定する.

4. ターゲット検出

ハイパースペクトル画像を用いたターゲット検出は監視や罹災者救助に役立つ [Manolakis 02]. ターゲット検出の基盤となる異常検出は, 周辺画素のスペクトルと明らかに異なるスペクトル特性を有する画素を特定する技術である. 有名な異常検出手法には Reed-Xiaoli 検出器 (RXD: Reed-Xiaoli Detector) [Reed 90] がある. RXD は数学的には PCA の逆演算とみなせ, 背景スペクトルの下位の主成分に特徴をもつスペクトルを異常として検出する手法である. RXD は, 統計学におけるマハラノビス距離と同義であり, 信号処理における整合フィルタ (Matched Filter) で解析対象スペクトルを信号とすることと同じでもある. RXD の性能は, 背景スペクトルの分散共分散行列をいかに正確に推定できるかに依存する. 背景が均一な場合は画像全体から分散共分散行列を推定すればよいが, そうでない場合は, 局所窓やセグメンテーションを利用して局所的に背景の特性を求める必要がある. RXD の拡張により, 異常検出と検出物の分類をリアルタイムに実現できる [Chang 02].

特定物体の存在を識別するターゲット検出を実現するためには, 物体のスペクトル情報が事前知識として必要となる. ピクセルサイズのターゲット検出には適応型整合フィルタ (AMF: Adaptive Matched Filter) [Robey 92] が有効である. AMF は整合フィルタの信号にターゲットスペクトルを設定し, 局所的な背景の特性を考慮

する手法である. サブピクセルサイズのターゲットを検出する手法として, ターゲットと背景のスペクトル特性を線形部分空間でモデル化する部分空間整合検出器 (MSD: Matched Subspace Detector) [Scharf 94] が有力である. 複数のターゲットスペクトルが必要となるが, ターゲットスペクトルのばらつきとスペクトル混合を考慮できるため, AMF よりも頑健な手法である. ミクセル分解を応用することでサブピクセルレベルのターゲット検出を実現できる [Chang 00]. ただし, 計算コストが増大するため, リアルタイム処理を実装する場合には, AMF や MSD が有利である. ターゲットと背景のスペクトル辞書を活用するスパース表現を用いる手法は, 従来のターゲット検出手法を上回る性能を示した [Chen 11]. ターゲット検出を実装する際には, センサ特性や大気の影響を考慮してターゲットスペクトルと観測スペクトルを一貫性のあるデータとすることが重要である.

図 8 にターゲット検出の例を示す. Hyperspec-VNIR (Headwall Photonics, Inc.) で駒場リサーチキャンパスとその周辺を航空撮影し, 屋上に設置した緑色ビニールシートを検出対象物とした. 地上計測した教師スペクトルを用いて, AMF とミクセル分解に基づく手法を組み合わせ得られる相対検出応答分布図は図 8 下のとおりである. 図 8 右上の拡大図に示すとおり, ハイパースペクトル画像の地上サンプリング幅は 2.5 m で検出物と同程度であるため, 検出物はミクセルとなる. AMF とミクセル分解を組み合わせることで図 8 下拡大図に示すとおり, 雑然とした背景の中でもターゲットを含む画素は高い検出応答を示している. 高次元のスペクトル情報を活用することで, 従来のマルチスペクトル画像解析や, カラー画像を使った人間の目視判読では難しいサブピクセルサイズの物体を自動で検出することができる.




図 8 航空撮影ハイパースペクトル画像を用いたターゲット検出

5. 高解像度化

ハイパースペクトルセンサはSNRの制約からマルチスペクトルセンサよりも空間分解能が低い。衛星搭載型では地上サンプリング幅が30 m程度であるために利用用途が限定される。マルチスペクトル画像の高解像度化技術としては、パンクロマティック画像を使ったパンシャープン技術が有名で、Google Mapの画像にも使われている。パンシャープンの歴史は長く、さまざまな手法が提案されている。パンシャープンをハイパースペクトル画像の高解像度化に応用することは可能である。しかし、パンシャープン手法の多くは空間方向の高周波成分の復元に着目しており、スペクトル方向の拘束条件が弱い場合、スペクトルのひずみを発生させることが知られている。ハイパースペクトル画像に関してスペクトルのひずみは致命的であり、この誤差を最小限に抑えつつ、空間的解像度を上げることが課題となる。

MAP (Maximum A Posteriori) / SMM (Stochastic Mixture Model) 法 [Eisman 04] は、マルチスペクトル画像を用いたハイパースペクトル画像の高解像度化に有効である。SMM から得られるクラス分類情報をもとに、マルチスペクトル画像とハイパースペクトル画像が観測された条件下での、未観測な高解像度ハイパースペクトル画像の事後確率分布を定式化する。この事後確率分布を最大化することで融合データを推定することができる。連成非負値行列因子分解 (CNMF: Coupled Nonnegative Matrix Factorization) [Yokoya 12] は、ミクセル分解を応用したハイパースペクトル画像とマルチスペクトル画像の融合手法として提案された。ハイパースペクトル画像から観測範囲に含まれる端成分スペクトルを推定し、マルチスペクトル画像からその高解像度な含有率分布図を求めることで両者の長所を併せもつ高解像度ハイパースペクトル画像が得られる (図9)。CNMFはクラス分類より1段階情報量が多いミクセル分解に基づいた手法であるため、MAP/SMMよりもスペクトルのひずみが小さい。スパース行列分解を

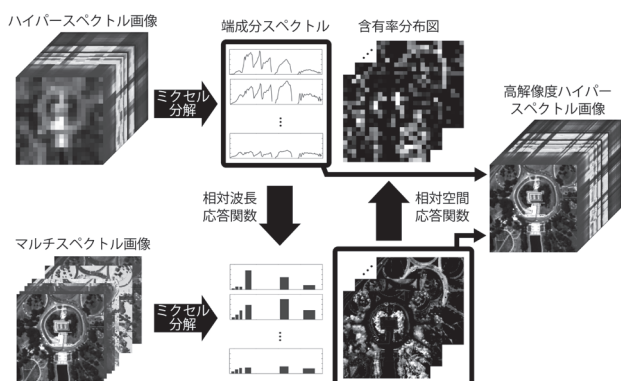


図9 ミクセル分解に基づくハイパースペクトル画像とマルチスペクトル画像のデータ融合




図10 719 nm の画像。
(左) 元のハイパースペクトル画像, (右) 高解像度化したハイパースペクトル画像

用いたミクセル分解により、カラー画像を使ったハイパースペクトル画像の高解像度化技術も提案されている [Kawakami 11]。

図8のハイパースペクトル画像と高解像度カラー画像に、CNMFを適用した結果を図10に示す。ハイパースペクトル画像のスペクトル情報とカラー画像の空間情報をミクセル分解に基づいて融合するため、高解像度なレッドエッジ (719 nm) 画像を推定できる。HISUI, EnMAP, PRISMA, HypSIRI のデータも、より高解像度なマルチスペクトルセンサと組み合わせて空間解像度を向上させることで、幅広い分野での利用が可能となる。

6. おわりに

本稿では、地球観測における最新のハイパースペクトルデータ処理技術を紹介した。高次元なスペクトル情報を最大限活用することで、従来の光学センサでは難しかった高度な地表面の情報解析が可能となる。HISUIをはじめとする衛星搭載型ハイパースペクトルセンサと知的情報処理の融合は、地球観測の知能化に資する一步となることが期待される。

◇ 参考文献 ◇

- [Adams 86] Adams, J. B., Smith, M. O. and Johnson, P. E.: Spectral mixture modeling: A new analysis of rock and soil types at the Viking Lander I site, *J. Geophys. Res.*, Vol. 91, pp. 8098-8112 (1986)
- [Barnsley 04] Barnsley, M. J., Settle, J. J., Cutter, M. A., Lobb, D. R. and Teston, F.: The PROBA/CHRIS mission: A low-cost smallsat for hyperspectral multiangle observations of the Earth surface and atmosphere, *IEEE Trans. Geosci. Remote Sens.*, Vol. 42, No. 7, pp. 1512-1520 (2004)
- [Bayliss 97] Bayliss, J., Gualtieri, J. A. and Cromp, R.: Analysing hyperspectral data with independent component analysis, *Proc. SPIE*, Vol. 3240, pp. 133-143 (1997)
- [Benediktsson 99] Benediktsson, J. A. and Kanellopoulos, I.: Classification of multisource and hyperspectral data based on decision fusion, *IEEE Trans. Geosci. Remote Sens.*, Vol. 37, No.

- 3, pp. 1367-1377 (1999)
- [Benediktsson 05] Benediktsson, J. A., Palmason, J. A. and Sveinsson, J. R.: Classification of hyperspectral data from urban areas based on extended morphological profiles, *IEEE Trans. Geosci. Remote Sens.*, Vol. 43, No. 3, pp. 480-491 (2005)
- [Bibring 06] Bibring, J.-P., et al.: Global mineralogical and aqueous mars history derived from OMEGA/Mars express data, *Science*, Vol. 312, pp. 400-404 (2006)
- [Bioucas-Dias 09] Bioucas-Dias, J. M.: A variable splitting augmented lagrangian approach to linear spectral unmixing, *Proc. IEEE WHISPERS*, pp. 1-4 (2009)
- [Bioucas-Dias 12] Bioucas-Dias, J., Plaza, A., Dobigeon, N., Parente, M., Du, Q., Gader, P. and Chanussot, J.: Hyperspectral unmixing overview: Geometrical, statistical, and sparse regression-based approaches, *IEEE J. Select. Topics Appl. Earth Observ. Remote Sensing*, Vol. 5, No. 2, pp. 354-379 (2012)
- [Bioucas-Dias 13] Bioucas-Dias, J. M., Plaza, A., Camps-Valls, G., Scheunders, P., Nasrabadi, N., M. and Chanussot, J.: Hyperspectral remote sensing data analysis and future challenges, *IEEE Geosci. Remote Sensing Magazine*, Vol. 1, No. 2, pp. 6-36 (2013)
- [Boardman 93] Boardman, J.: Automating spectral unmixing of AVIRIS data using convex geometry concepts, *Proc. Ann. JPL Airborne Geosci. Workshop*, Vol. 1, pp. 11-14 (1993)
- [Bruzzone 06] Bruzzone, L., Chi, M. and Marconcini, M.: A novel transductive SVM for the semisupervised classification of remote sensing images, *IEEE Trans. Geosci. Remote Sens.*, Vol. 44, No. 11, pp. 3363-3373 (2006)
- [Camps-Valls 06] Camps-Valls, G., Gomez-Chova, L., Munoz-Mari, J., Vila-Frances, J. and Calpe-Maravilla, J.: Composite kernels for hyperspectral image classification, *IEEE Geosci. Remote Sens. Lett.*, Vol. 3, pp. 93-97 (2006)
- [Chang 00] Chang, C.-I. and Heinz, D. C.: Constrained subpixel target detection for remotely sensed imagery, *IEEE Trans. Geosci. Remote Sensing*, Vol. 38, No. 3, pp. 1144-1159 (2000)
- [Chang 02] Chang, C.-I. and Chiang, S.-S.: Anomaly detection and classification for hyperspectral imagery, *IEEE Trans. Geosci. Remote Sens.*, Vol. 40, No. 6, pp. 1314-1325 (2002)
- [Chien 09] Chien, S.: Onboard science processing concepts for the HypIRI mission, *IEEE Intelligent Systems*, Vol. 24, No. 6, pp. 12-19 (2009)
- [Chen 11] Chen, Y., Nasrabadi, N. and Tran, T.: Sparse representation for target detection in hyperspectral imagery, *IEEE J. Select. Topics Signal Processing*, Vol. 5, No. 3, pp. 629-640 (2011)
- [Clark 84] Clark, R. N. and Roush, T. L.: Reflectance spectroscopy: Quantitative analysis techniques for remote sensing applications, *J. Geophys. Res.*, Vol. 89, pp. 6329-6340 (1984)
- [Clark 05] Clark, M. L., Roberts, D. A. and Clark, D. B.: Hyperspectral discrimination of tropical rain forest tree species at leaf to crown scales, *Remote Sens. Environ.*, Vol. 96, pp. 375-398 (2005)
- [Dalponte 08] Dalponte, M., Bruzzone, L. and Gianelle, D.: Fusion of hyperspectral and lidar remote sensing data for classification of complex forest areas, *IEEE Trans. Geosci. Remote Sens.*, Vol. 46, No. 5, pp. 1416-1427 (2008)
- [Eismann 04] Eismann, M. T. and Hardie, R. C.: Application of the stochastic mixing model to hyperspectral resolution enhancement, *IEEE Trans. Geosci. Remote Sens.*, Vol. 42, No. 9, pp. 1924-1933 (2004)
- [Galeazzi 08] Galeazzi, C., Sacchetti, A., Cisbani, A. and Babini, G.: The PRISMA program, *Proc. IEEE IGARSS*, Vol. 4, pp. 105-108 (2008)
- [Gowen 07] Gowen, A. A., O'Donnell, C. P., Cullen, P. J., Downey, G. and Frias, J. M.: Hyperspectral imaging - an emerging process analytical tool for food quality and safety control, *Trends in Food Science & Technology*, Vol. 18, No. 12, pp. 590-598 (2007)
- [Goetz 85] Goetz, A. F. H., Vane, G., Solomon, J. E. and Rock, B. N.: Imaging spectrometry for earth remote sensing, *Science*, Vol. 228, pp. 1147-1153 (1985)
- [Green 88] Green, A. A., Berman, M., Switzer, P. and Craig, M. D.: A transformation for ordering multispectral data in terms of image quality with implications for noise removal, *IEEE Trans. Geosci. Remote Sens.*, Vol. 26, No. 1, pp. 65-74, (1988)
- [Haboudane 04] Haboudane, D., Miller, J. R., Pattey, E., Zarco-Tejada P. J. and Strachan, I. B.: Hyperspectral vegetation indices and novel algorithms for predicting green LAI of crop canopies: Modeling and validation in the context of precision agriculture, *Remote Sens. Environ.*, Vol. 90, No. 3, pp. 337-352 (2004)
- [Ham 05] Ham, J., Chen, Y., Crawford, M. M. and Ghosh, J.: Investigation of the random forest framework for classification of hyperspectral data, *IEEE Trans. Geosci. Remote Sens.*, Vol. 43, No. 3, pp. 492-501 (2005)
- [Heinz 01] Heinz, D. C. and Chang, C.-I.: Fully constrained least squares linear spectral mixture analysis method for material quantification in hyperspectral imagery, *IEEE Trans. Geosci. Remote Sens.*, Vol. 39, No. 3, pp. 529-545 (2001)
- [Iordache 11] Iordache, M. D., Bioucas-Dias, J. and Plaza, A.: Sparse unmixing of hyperspectral data, *IEEE Trans. Geosci. Remote Sens.*, Vol. 49, No. 6, pp. 2014-2039 (2011)
- [Itoh 13] Itoh, Y. and Iwasaki, A.: Enhancement of hyperspectral unmixing using continuum removal, *Proc. IEEE IGARSS*, pp. 445-448 (2013)
- [Kawakami 11] Kawakami, R., Wright, J., Tai, Y. W., Ben-Ezra, M., Matsushita, Y. and Ikeuchi, K.: High-resolution hyperspectral imaging via matrix factorization, *Proc. CVPR*, pp. 2329-2336 (2011)
- [Keshava 02] Keshava, N. and Mustard, J. F.: Spectral unmixing, *IEEE Signal Processing Magazine*, Vol. 19, pp. 44-57 (2002)
- [Kruse 03] Kruse, F. A., Boardman, J. W., and Huntington, J. F.: Comparison of airborne hyperspectral data and EO-1 hyperion for mineral mapping, *IEEE Trans. Geosci. Remote Sens.*, Vol. 41, No. 6, pp. 1388-1400 (2003)
- [Kumar 01] Kumar, S., Ghosh, J. and Crawford, M. M.: Best-bases feature extraction algorithms for classification of hyperspectral data, *IEEE Trans. Geosci. Remote Sens.*, Vol. 39, No. 7, pp. 1368-1379 (2001)
- [Landgrebe 03] Landgrebe, D. A.: *Signal Theory Methods in Multispectral Remote Sensing*, Hoboken, NJ: Wiley (2003)
- [Lee 99] Lee, D. D. and Seung, H. S.: Learning the parts of objects by nonnegative matrix factorization, *Nature*, Vol. 401, No. 6755, pp. 788-791 (1999)
- [Lyon 02] Lyon, R. C., Lester, D. S., Lewis, E. N., Lee, E., Yu, L. X. and Jefferson, E. H., et al.: Near-infrared spectral imaging for quality assurance of pharmaceutical products: Analysis of tablets to assess powder blend homogeneity, *AAPS PharmSciTech*, Vol. 3, No. 3, p. 17 (2002)
- [Manolakis 02] Manolakis, D. and Shaw, G.: Detection algorithms for hyperspectral imaging applications, *IEEE Signal Processing Magazine*, Vol. 19, No. 1, pp. 29-43 (2002)
- [Matsuki 14] Matsuki, T., Yokoya, N. and Iwasaki, A.: Hyperspectral tree species classification with an aid of LiDAR data, *Proc. IEEE WHISPERS*, to be published (2014)
- [Melgani 04] Melgani, F. and Bruzzone, L.: Classification of hyperspectral remote sensing images with support vector machines, *IEEE Trans. Geosci. Remote Sens.*, Vol. 42, No. 8, pp. 1778-1790 (2004)
- [Miao 07] Miao, L. and Qi, H.: Endmember extraction from highly mixed data using minimum volume constrained nonnegative matrix factorization, *IEEE Trans. Geosci. Remote Sens.*, Vol. 45, No. 3, pp. 765-777 (2007)
- [Middleton 13] Middleton, E. M., et al.: The earth observing one (EO-1) satellite mission: Over a decade in space, *IEEE J. Select. Topics Appl. Earth Observ. Remote Sensing*, Vol. 6, No. 2, pp. 243-256 (2013)
- [Mustard 08] Mustard J. F., et al: Hydrated silicate minerals on Mars observed by the Mars Reconnaissance Orbiter CRISM instrument, *Nature*, Vol., 454, pp. 305-309 (2008)
- [Nascimento 05] Nascimento, J. M. P. and Bioucas-Dias, J.: Vertex component analysis: A fast algorithm to unmix

- hyperspectral data, *IEEE Trans. Geosci. Remote Sens.*, Vol. 43, No. 4, pp. 898-910 (2005)
- [Ohgi 10] Ohgi, N., Iwasaki, A., Kawashima, T. and Inada, H.: Japanese hyper-multi spectral mission, *Proc. IEEE IGARSS*, pp. 3756-3759 (2010)
- [Plaza 09] Plaza, A., et al.: Recent advances in techniques for hyperspectral image processing, *Remote Sens. Environ.*, Vol. 113, pp. 110-122 (2009)
- [Reed 90] Reed, S. and Yu, X.: Adaptive multiple-band CFAR detection of an optical pattern with unknown spectral distribution, *IEEE Trans. Acoust., Speech, Signal Process.*, Vol. 38, No. 10, pp. 1760-1770 (1990)
- [Roberts 93] Roberts, D. A., Smith, M., and Adams, J. B.: Green vegetation, nonphotosynthetic vegetation, and soils in AVIRIS data, *Remote Sens. Environ.*, Vol. 44, pp. 255-269 (1993)
- [Roberts 98] Roberts, D. A., Gardner, M., Church, R., Ustin, S., Scheer, G. and Green, R. O.: Mapping chaparral in the Santa Monica Mountains using multiple endmember spectral mixture models, *Remote Sens. Environ.*, Vol. 65, No. 3, pp. 267-279 (1998)
- [Robey 92] Robey, F., Fuhrmann, D. and Kelly, E.: A CFAR adaptive matched filter detector, *IEEE Trans. Aerosp. Electron. Syst.*, Vol. 28, No. 1, pp. 208-216 (1992)
- [Sang 08] Sang, B., et al.: The EnMAP hyperspectral imaging spectrometer: Instrument concept, calibration and technologies, *Proc. SPIE*, Vol. 7086, pp. 708605-1-708605-15 (2008)
- [Scharf 94] Scharf, L. and Friedlander, B.: Matched subspace detectors, *Signal Process.*, Vol. 42, No. 8, pp. 2146-2157 (1994)
- [Tuia 11] Tuia, D., Volpi, M., Copa, L., Kanevski, M. and Munoz-Mari, J.: A survey of active learning algorithms for supervised remote sensing image classification, *IEEE J. Select. Topics Signal Processing*, Vol. 5, No. 3, pp. 606-617 (2011)
- [Underwood 03] Underwood, E., Ustin, S. and DiPietro, D.: Mapping nonnative plants using hyperspectral imagery, *Remote Sens. Environ.*, Vol. 86, pp. 150-161 (2003)
- [Ungar 03] Ungar, S., Pearlman, J., Mendenhall, J. and Reuter, D.: Overview of the earth observing one (EO-1) mission, *IEEE Trans. Geosci. Remote Sens.*, Vol. 41, No. 6, pp. 1149-1159 (2003)
- [Ustin 04] Ustin S. L., Roberts, D. A., Gamon, J. A., Asner, G. P. and Green, R. O.: Using imaging spectroscopy to study ecosystem processes and properties, *Bioscience*, Vol. 54, No. 6, pp. 523-534 (2004)
- [Winter 99] Winter, M. E.: N-FINDR: An algorithm for fast autonomous spectral endmember determination in hyperspectral data, *Proc. SPIE Image Spectrometry V*, Vol. 3753, pp. 266-277 (1999)
- [Yokoya 12] Yokoya, N., Yairi, T. and Iwasaki, A.: Coupled nonnegative matrix factorization unmixing for hyperspectral and multispectral data fusion, *IEEE Trans. Geosci. Remote Sens.*, Vol. 50, No. 2, pp. 528-537 (2012)
- [Yuhas 92] Yuhas, R. H., Goetz, A. F. H. and Boardman, J. W.: Discrimination among semiarid landscape endmembers using the spectral angle mapper (SAM) algorithm, *Summaries of 3rd Annual JPL Airborne Geoscience Workshop*, JPL Publication 92-14, Vol. 1, pp. 147-149 (1992)
- [Zibulevsky 01] Zibulevsky, M. and Pearlmutter, B. A.: Blind source separation by sparse decomposition in a signal dictionary, *Neural Computation*, Vol. 13, No. 4, pp. 863-882 (2001)

2014年6月2日 受理

著者紹介



横矢 直人

2013年東京大学大学院工学系研究科博士課程修了。博士(工学)。同年、東京大学大学院工学系研究科助教。地球観測画像データからの情報抽出に関する研究開発に従事。IEEE、日本リモートセンシング学会などの各会員。



岩崎 晃

1987年東京大学大学院工学系研究科修了。同年、電子技術総合研究所入所。2004年東京大学大学院工学系研究科助教授、2008年同教授。博士(工学)。宇宙利用工学、地球観測機器およびデータ処理に関する研究開発に従事。日本リモートセンシング学会、日本航空宇宙学会などの各会員。